

DEPARTEMEN TEKNIK ELEKTRO · FTEIC · INSTITUT TEKNOLOGI SEPULUH NOPEMBER

ELEKTRONIKA CERDAS (SEMESTER GASAL 2026/2027)

TUGAS PROYEK: PREDIKSI DIABETES BERBASIS CUSTOM DEEP NEURAL NETWORK

Clinical Decision Support System & Desktop Application

Target: Desktop GUI App
Engine: TensorFlow / PyTorch
Platform: MyITS Classroom
Format: Berkas ZIP (.zip)

1. Deskripsi & Tujuan Proyek (Assignment Overview)

Tujuan utama proyek ini adalah merancang, membangun, mengevaluasi, dan menggelar (*deploy*) sebuah aplikasi *machine learning* klinis berbasis desktop secara mandiri dari awal (*from the ground up*). Mahasiswa ditantang untuk mengembangkan sistem pendukung keputusan medis (*Clinical Decision Support System*) yang mampu memprediksi risiko penyakit diabetes mellitus berdasarkan profil rekam medis pasien secara akurat dan terpercaya. Proyek ini menguji dan mengasah kompetensi mahasiswa dalam ranah:

- Data Preprocessing & Pipeline Engineering:** Pembersihan data, imputasi, *categorical encoding*, penskalaan numerik tanpa kebocoran data (*data leakage*), serta penanganan ketidakseimbangan kelas (*class imbalance*).
- Custom Deep Neural Network Design:** Perancangan arsitektur Multi-Layer Perceptron (MLP) dengan eksplorasi kedalaman (*depth*), lebar (*width*), regularisasi (*Dropout*, *Batch Normalization*), dan optimasi.
- Formulasi Matematis Output Layer:** Implementasi dan komparasi mendalam antara fungsi aktivasi **Sigmoid** vs **Softmax** beserta penyesuaian *loss function* yang relevan.
- Graphical User Interface (GUI) Development:** Pembangunan antarmuka grafis desktop modern, ergonomis, dan responsif (menggunakan Tkinter, CustomTkinter, atau PyQt).
- End-to-End System Integration:** Integrasi utuh antara model terlatih, pipeline transformasi, dan antarmuka GUI untuk inferensi klinis secara *real-time*.


2. Spesifikasi Lingkungan Teknis (Technical Stack)

Mahasiswa diwajibkan menggunakan ekosistem pustaka Python 3 dengan spesifikasi standar sebagai berikut:

Komponen	Pustaka / Tools	Kegunaan Utama
Bahasa Pemrograman	Python 3.9+	Lingkungan komputasi dan skrip aplikasi utama
Deep Learning Engine	TensorFlow (Keras) / PyTorch	Pembangunan, kompilasi, pelatihan, dan ekspor model ANN
Manipulasi Data	Pandas, NumPy	Eksplorasi dataset, vektorisasi data, dan kalkulasi matriks
Preprocessing & Metrik	Scikit-learn	Encoding kategori, scaling numerik, data splitting, evaluasi
GUI Desktop Framework	Tkinter / CustomTkinter / PyQt	Pembangunan antarmuka grafis interaktif dan event binding
Serialisasi Pipeline	Joblib / Pickle, Keras (.keras/.h5)	Penyimpanan objek scaler/encoder dan bobot model terlatih

3. Diagram Alur Kerja Sistem (End-to-End Workflow Pipeline)

Berikut adalah ilustrasi alur rekayasa sistem cerdas end-to-end yang harus dilalui dalam pelaksanaan proyek ini:



4. Spesifikasi & Karakteristik Dataset

Dataset yang digunakan berasal dari basis data publik **Kaggle Diabetes Prediction Dataset**:

URL Dataset Resmi: <https://www.kaggle.com/datasets/iammustafatz/diabetes-prediction-dataset>

Dataset terdiri dari **100.000 sampel data rekam medis** dengan 8 fitur prediktor dan 1 variabel target:

Nama Fitur	Tipe Data	Rentang / Kategori	Keterangan Klinis & Rekomendasi Preprocessing
gender	Kategorik	Female, Male, Other	Jenis kelamin pasien. Terapkan One-Hot atau Label Encoding.
age	Numerik	0.08 – 80.0 tahun	Usia pasien. Standarisasi menggunakan StandardScaler .
hypertension	Biner	0 (Tidak), 1 (Ya)	Riwayat kondisi tekanan darah tinggi. Fitur indikator biner.
heart_disease	Biner	0 (Tidak), 1 (Ya)	Riwayat penyakit kardiovaskular. Fitur indikator biner.
smoking_history	Kategorik	6 kategori unik	Riwayat merokok (<i>never, current, former, No Info, dll.</i>).
bmi	Numerik	10.01 – 95.69 kg/m ²	<i>Body Mass Index</i> . Lakukan penskalaan numerik.
HbA1c_level	Numerik	3.5 – 9.0%	Kadar hemoglobin terglikasi (ambang medis diabetes ≥ 6.5%).
blood_glucose_level	Numerik	80 – 300 mg/dL	Konsentrasi glukosa darah saat pengujian glikemik.
diabetes (Target)	Biner	0 (Negatif), 1 (Positif)	Status klinis diabetes mellitus. Variabel target klasifikasi.

Tantangan Khusus: Ketidakseimbangan Kelas (*Class Imbalance Challenge*)

Dataset memiliki proporsi kelas yang sangat timpang: **91.500 sampel Negatif (91,5%)** dan **8.500 sampel Positif (8,5%)**. Model naif yang memprediksi seluruh data bernilai 0 akan memperoleh akurasi 91,5%, namun gagal total mendeteksi pasien diabetes (*Accuracy Paradox*).

Instruksi Penting: Mahasiswa **TIDAK BOLEH** hanya mengandalkan metrik Akurasi! Evaluasi **Recall / Sensitivitas** (menghindari *False Negative* yang berisiko fatal secara medis), **Precision**, **F1-Score**, dan **Confusion Matrix** wajib disajikan. Eksplorasi teknik mitigasi seperti pembobotan kelas (`class_weight='balanced'`) atau penyesuaian ambang batas klasifikasi (*decision threshold tuning*) sangat dianjurkan.

5. Tahapan Pengerjaan Proyek (Implementation Phases)


Proyek ini terbagi ke dalam 3 fase utama yang saling berkesinambungan:

5.1 Fase I: Data Science & Pengembangan Model (Model Development)

Fase ini berfokus pada eksplorasi data, rekayasa fitur, serta perancangan dan pelatihan model *Artificial Neural Network* berkualitas tinggi.

- Eksplorasi & Pembagian Data (Train/Val/Test Split):** Bagi dataset menjadi data pelatihan (*Train*), validasi (*Validation*), dan pengujian (*Test*) menggunakan rasio terstandarisasi (misal 70 : 15 : 15 atau 80 : 10 : 10) dengan metode *Stratified Sampling* agar proporsi kelas target tetap terjaga di setiap partisi.
- Preprocessing & Pencegahan Data Leakage:** Lakukan pembersihan data, pengolahan kategori, dan penskalaan fitur numerik (**StandardScaler** atau **MinMaxScaler**). **Kaidah Kritis:** Seluruh transformer harus **di-fit HANYA** pada data *Train*, lalu diterapkan (*transform*) pada data *Validation* dan *Test* untuk mencegah kebocoran informasi.
- Desain & Komparasi Minimal Dua Arsitektur Neural Network:** Mahasiswa diwajibkan merancang, melatih, dan membandingkan performa **minimal dua arsitektur Custom Neural Network yang berbeda** (Model A vs Model B) untuk menentukan arsitektur terbaik. Variasikan parameter berikut:
 - Kedalaman model (*depth* / jumlah *hidden layers*).
 - Lebar layer (*width* / jumlah neuron per layer).
 - Teknik regularisasi (penerapan *Dropout* 0.2 – 0.4, *Batch Normalization*, atau *L2 Regularization*).
 - Tingkat laju pembelajaran (*learning rate*) dan penjadwalan laju (*learning rate scheduler*).

Visualisasi Topologi Arsitektur Custom Multi-Layer Perceptron (MLP)



5.1.1 Pemilihan Layer Output (Pilihan Mahasiswa: Sigmoid vs Softmax)

Mahasiswa memiliki kebebasan akademik untuk memilih fungsi aktivasi layer output. Anda wajib mengimple-mentasikan **salah satu dari dua opsi berikut** dan memberikan justifikasi teoretis serta empiris pada laporan akhir:

Karakteristik	Opsi A: Aktivasi Sigmoid	Opsi B: Aktivasi Softmax
Jumlah Neuron Output	Tepat 1 neuron pada layer terakhir	Tepat 2 neuron pada layer terakhir
Formulasi Matematis	$\sigma(z) = \frac{1}{1 + e^{-z}} \in [0, 1]$	$P(y = i \mid \mathbf{z}) = \frac{e^{z_i}}{\sum_{j=1}^2 e^{z_j}}, \quad i \in \{0, 1\}$
Format Label Target	Bilangan bulat skalar ($y \in \{0, 1\}$)	<i>One-Hot Encoded</i> ($\mathbf{y} \in \{[1, 0], [0, 1]\}$)
Fungsi Loss	<code>binary_crossentropy</code>	<code>categorical_crossentropy</code>
Formulasi Loss	$\mathcal{L}_{\text{BCE}} = -[y \ln(\hat{y}) + (1 - y) \ln(1 - \hat{y})]$	$\mathcal{L}_{\text{CCE}} = -\sum_{i=1}^2 y_i \ln(\hat{y}_i)$
Interpretasi Output	Probabilitas tunggal kelas positif ($P(\text{Diabetes})$)	Distribusi probabilitas atas kedua kelas (P_0, P_1)
Logika Keputusan	Jika $\hat{y} \geq \theta$ (default $\theta = 0.5$), maka Positif	Ambil argumen maksimum: $\text{argmax}(\hat{y}_0, \hat{y}_1)$

4. **Evaluasi Metrik & Seleksi Model Terbaik:** Evaluasi model menggunakan metrik: **Accuracy, Precision, Recall, F1-Score, dan Confusion Matrix**. Pilih **salah satu model terbaik** berdasarkan performa generalisasi klinis pada *Test Set* untuk diintegrasikan ke dalam antarmuka desktop.
5. **Penyimpanan Model & Preprocessor Pipeline:** Simpan model terbaik ke dalam file biner (format `.keras` atau `.h5`). Simpan pula objek transformer (`StandardScaler` dan encoder kategori) menggunakan `joblib` atau `pickle` ke file `preprocessor.pkl`. Hal ini sangat krusial agar GUI dapat memproses data input pengguna dengan transformasi identik.

5.2 Fase II: Pengembangan GUI Desktop (GUI Development)

Pada fase ini, mahasiswa merancang antarmuka grafis desktop yang mengadaptasi rancangan terlampir (merefensikan tata letak pada dokumen acuan):

Gambar 1: Mockup Desain Antarmuka Aplikasi Desktop: *Diabetes Prediction System*

Spesifikasi Komponen Antarmuka GUI:

- **Judul Jendela Utama:** Diberi judul "Diabetes Prediction System" atau "Sistem Prediksi Diabetes".
- **Panel Kiri ("Patient Information"):** Memuat 8 kontrol input klinis:
 - 4 **Dropdown / Combobox (Kategorik):** Gender (*Female, Male, Other*), Hypertension (*0, 1*), Heart Disease (*0, 1*), Smoking History (*never, current, former, ever, not current, No Info*).
 - 4 **Kotak Teks / Entry (Numerik):** Usia (Age, tahun), Indeks Massa Tubuh (BMI, kg/m^2), Kadar HbA1c (%), dan Glukosa Darah (Blood Glucose, mg/dL).
- **Panel Kanan ("Diabetes Diagnosis"):** Memuat visualisasi hasil inferensi:
 - Label status diagnosis yang kontras dan jelas ("**Negative / Non-Diabetic**" berwarna hijau atau "**Positive / Diabetic**" berwarna merah).
 - Tingkat keyakinan model (*Confidence Score*, misal "**0.982**" atau "**98.2%**").
 - Tombol aksi utama "**Predict**" untuk mengeksekusi inferensi.
 - Tombol "**Reset**" untuk mengembalikan nilai form ke kondisi awal.

5.3 Fase III: Integrasi Sistem & Aplikasi Mandiri (System Integration)

Fase ini menggabungkan bobot model terlatih, objek preprocessing, dan logika interaksi antarmuka GUI:

1. **Pemuatan Model & Objek Preprocessing (Scaler / Encoder):** Saat aplikasi desktop diluncurkan, program secara otomatis memuat file model (*.keras* atau *.h5*) dan pipeline objek preprocessor (*preprocessor.pkl*) yang memuat scaler dan encoder tersimpan dari Scikit-Learn).
2. **Ekstraksi & Validasi Input:** Saat tombol "**Predict**" ditekan, sistem mengambil seluruh 8 nilai input. Lakukan validasi data untuk menangkap masukan kosong atau tidak valid (tampilkan jendela pesan peringatan dialog pop-up yang informatif jika terjadi kesalahan input).
3. **Transformasi Pipeline yang Konsisten:** Konversikan data input klinis pengguna menggunakan objek scaler dan encoder yang identik dengan proses pelatihan model pada Fase I.
4. **Eksekusi Inferensi & Tampilan Hasil:** Umpankan array fitur yang telah dinormalisasi ke model, hitung probabilitas, dan tampilkan status diagnosis serta persentase keyakinan secara instan dan interaktif pada Panel Kanan.

6. Luaran Proyek & Ketentuan Pengumpulan (Deliverables)

Setiap mahasiswa diwajibkan mengumpulkan berkas proyek dalam satu file arsip terkompresi (**.zip**) dengan format penamaan: **TugasProyek_EC_NamaLengkap_NRP.zip** melalui platform **MyITS Classroom**:

1. Source Code Terstruktur:

- **Jupyter Notebook (.ipynb)**: Berisi kode lengkap dari pembersihan data, EDA, rekayasa fitur, eksperimentasi pelatihan model A vs model B, visualisasi metrik evaluasi (Confusion Matrix, ROC Curve), dan proses ekspor model.
- **Python GUI Script (.py)**: Skrip aplikasi mandiri yang memuat kode GUI desktop dan integrasi backend inferensi.
- **Transformer Pipeline Artifact (.pkl / .joblib)**: Objek scaler dan encoder tersimpan.

2. File Model Terlatih: File model biner terbaik yang siap digunakan (`model.keras` atau `model.h5`).

3. Laporan Teknis Proyek (PDF): Dokumen laporan komprehensif yang memuat metodologi preprocessing data klinis, pencegahan data leakage, rincian arsitektur model, tabel perbandingan metrik klinis, justifikasi output layer (*Sigmoid* vs *Softmax*), dan panduan instalasi serta pengoperasian GUI (*User Guide*).

4. Video Demonstrasi Aplikasi (Durasi 1–3 Menit): Rekaman layar menunjukkan fungsionalitas aplikasi desktop secara langsung, memperlihatkan pengujian beberapa skenario data pasien (pasien sehat vs pasien berisiko diabetes).

7. Rubrik Penilaian Proyek (Assessment Rubric)

Penilaian dilakukan secara objektif dengan bobot total 100% mengacu pada rubrik evaluasi berikut:

Kriteria Penilaian	Bobot	Indikator Keunggulan Performa
Data Preprocessing & Pipeline Integrity	20%	Pembersihan data tepat, penanganan kategori dan imputasi valid, fitur diskalakan dengan benar, pembagian dataset terhindar dari <i>data leakage</i> , dan analisis tantangan <i>class imbalance</i> dilakukan secara tepat.
Arsitektur, Pelatihan & Evaluasi ANN	25%	Merancang dan membandingkan minimal 2 arsitektur neural network berbeda (kedalaman, lebar, regularisasi), justifikasi pemilihan layer output (<i>Sigmoid</i> vs <i>Softmax</i>) logis, dan metrik evaluasi komprehensif (Precision, Recall, F1, Matrix).
Ergonomi & Desain GUI Desktop	20%	Antarmuka mereplikasi spesifikasi desain (panel input dan output terpisah), memiliki seluruh 8 kontrol input klinis, tampilan modern, rapi, responsif, dan kode warna hasil intuitif.
Integrasi Sistem & Logika Inferensi	15%	Model dan scaler dimuat secara dinamis, input pengguna ditransformasikan dengan akurat sesuai pipeline training, inferensi <i>real-time</i> akurat, dan validasi input mencegah aplikasi <i>crash</i> .
Kualitas Laporan Teknis & Video Demo	20%	Laporan ditulis secara terstruktur, ilmiah, dan mendalam; video demonstrasi jelas memperlihatkan fungsionalitas penuh aplikasi dalam rentang durasi 1–3 menit.

— Departemen Teknik Elektro FTEIC ITS · Laboratorium Elektronika Cerdas —