EVALUASI TENGAH SEMESTER (ETS) — SIFAT: TERBUKA

Laporan Jawaban ETS

Mata Kuliah: Dasar Sistem Elektronika Cerdas

Soal 1 (Bobot 50%) — Rancang Bangun Aplikasi Desktop Prediksi Risiko Diabetes Berbasis Deep Learning

Nama Mahasiswa	:	.....
NRP	:	07.....
Program Studi	:	Teknik Elektro
Fakultas	:	Teknologi Industri dan Kemaritiman
Semester	:	Gasal 2026/2027

Departemen Teknik Elektro — FTEIC — Institut Teknologi Sepuluh Nopember
Surabaya, 2026

DAFTAR ISI

Soal 1 — Aplikasi Desktop Prediksi Risiko Diabetes
1.1 Analisis dan Preprocessing Data
1.2 Pemilihan Model dan Aturan Visualisasi
1.3 Evaluasi Model (Matriks Konfusi & Metrik Klinis)
1.4 Perancangan Antarmuka Pengguna (UI)
Kesimpulan
Daftar Pustaka

SOAL 1 — APLIKASI DESKTOP PREDIKSI RISIKO DIABETES

Sistem yang dirancang adalah aplikasi desktop berbasis Python yang berfungsi sebagai Clinical Decision Support System (CDSS): pengguna memasukkan 8 data klinis pasien secara manual, lalu aplikasi memprediksi "Risiko Diabetes" atau "Tidak Berisiko Diabetes" berdasarkan model deep learning (Multi-Layer Perceptron, TensorFlow/Keras) yang dilatih pada dataset Kaggle Diabetes Prediction Dataset. Alur pembangunan sistem secara keseluruhan: (1) analisis dan preprocessing dataset, (2) pembangunan & pelatihan model deep learning, (3) evaluasi klinis, (4) perancangan dan integrasi antarmuka pengguna.

1.1 Analisis dan Preprocessing Data

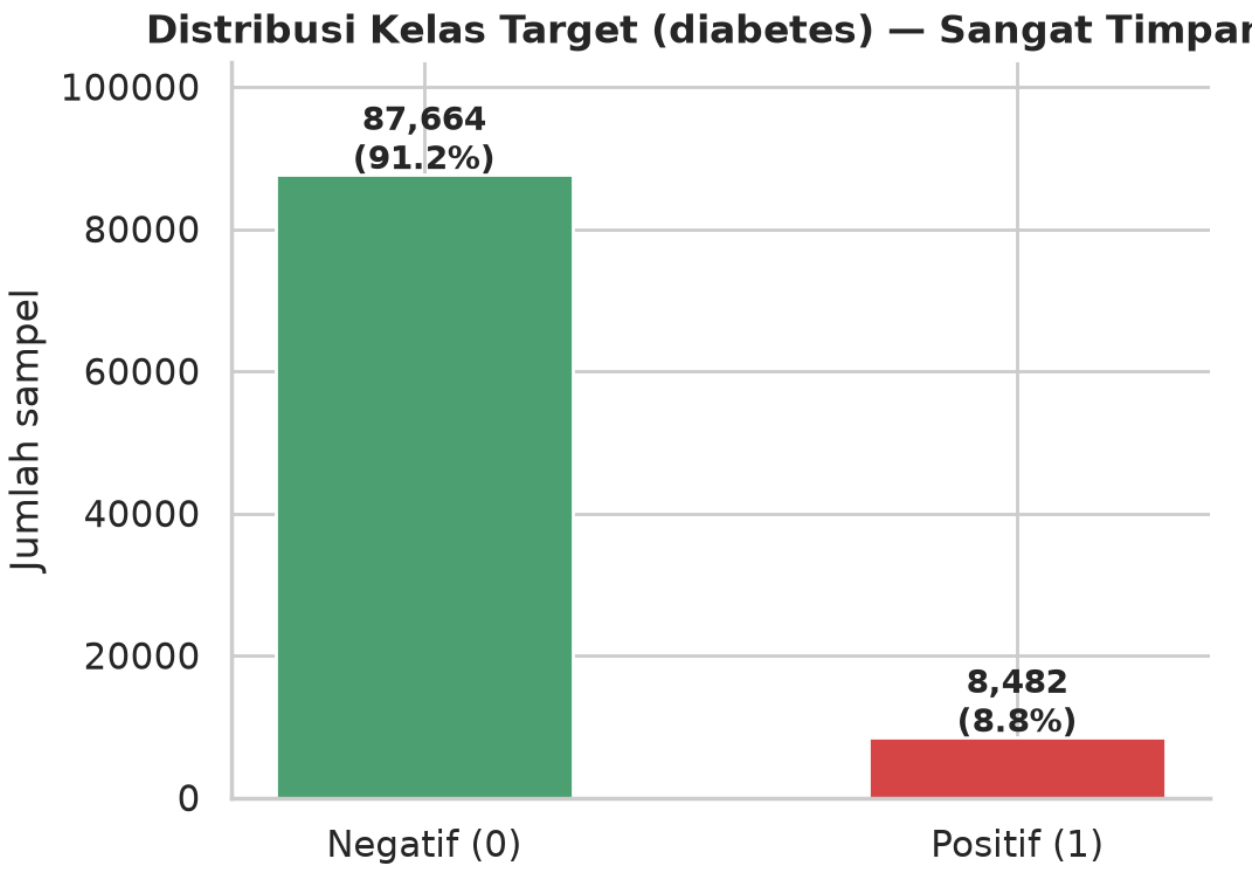
a. Deskripsi Dataset dan Atribut

Dataset acuan adalah Kaggle "Diabetes Prediction Dataset" (iamustafatz): 100.000 rekam medis dengan 8 fitur prediktor dan 1 target biner (diabetes: 1 = diabetic, 0 = non-diabetic). Ringkasan atribut:

Risiko meningkat seiring usia	
Faktor demografis	
Komorbid kardiovaskular	
Komorbid kardiovaskular	
Faktor gaya hidup	
current, No Info	
Indeks obesitas	
Rata-rata glikemik 2–3 bulan	
Gula darah saat pengujian	
Label kelas (8,82% positif)	

b. Analisis Data (EDA)

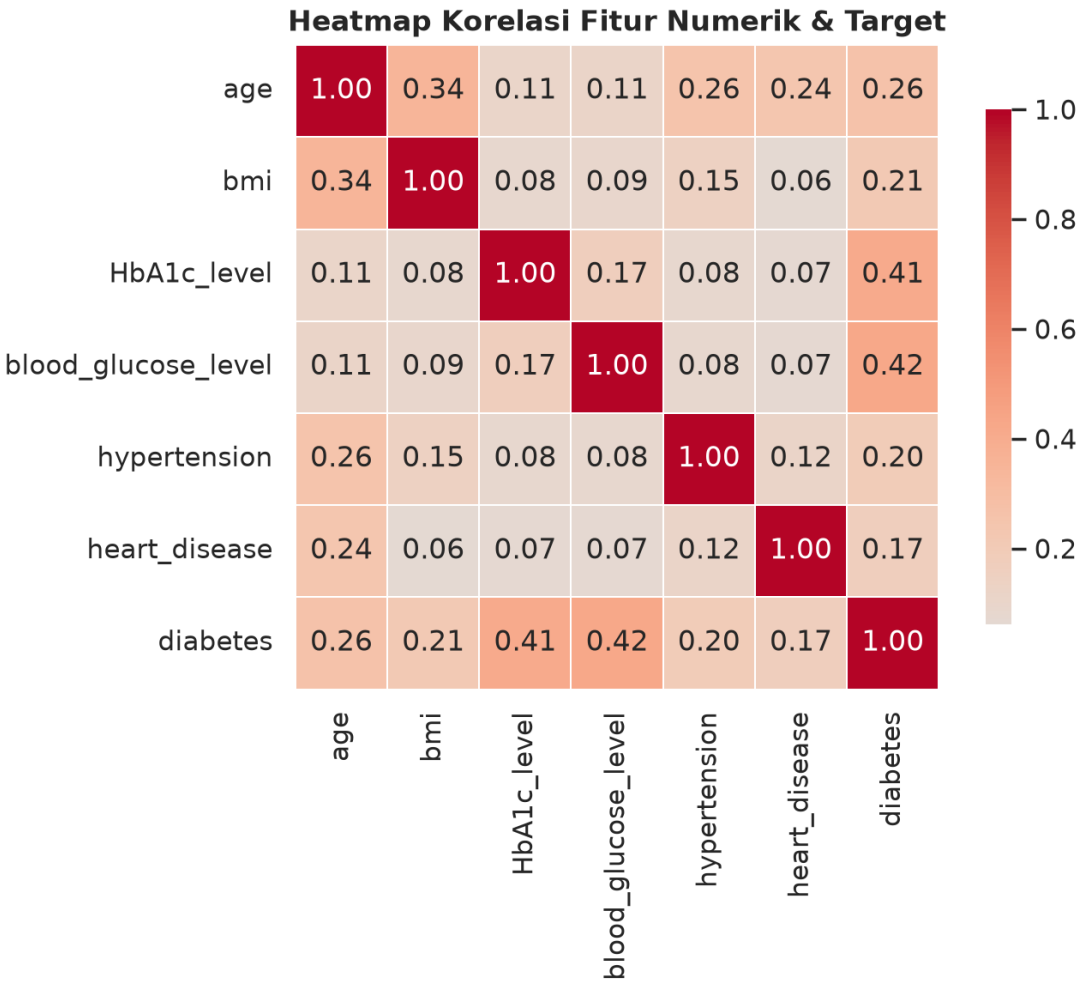
Analisis awal memperlihatkan: (i) distribusi target sangat imbang — 8.482 positif (8,82%) vs 87.664 negatif (91,18%), rasio ≈ 10,3 : 1, sehingga metrik accuracy bersifat "menipu" (accuracy paradox); (ii) statistik deskriptif fitur numerik: age (mean 41,8; std 22,5), bmi (mean 27,3; std 6,8), HbA1c (mean 5,53; std 1,07), glukosa (mean 138,2; std 40,9); (iii) korelasi positif terbesar terhadap target datang dari HbA1c, glukosa darah, dan usia; (iv) proporsi hipertensi 7,8% dan penyakit jantung 4,1%.



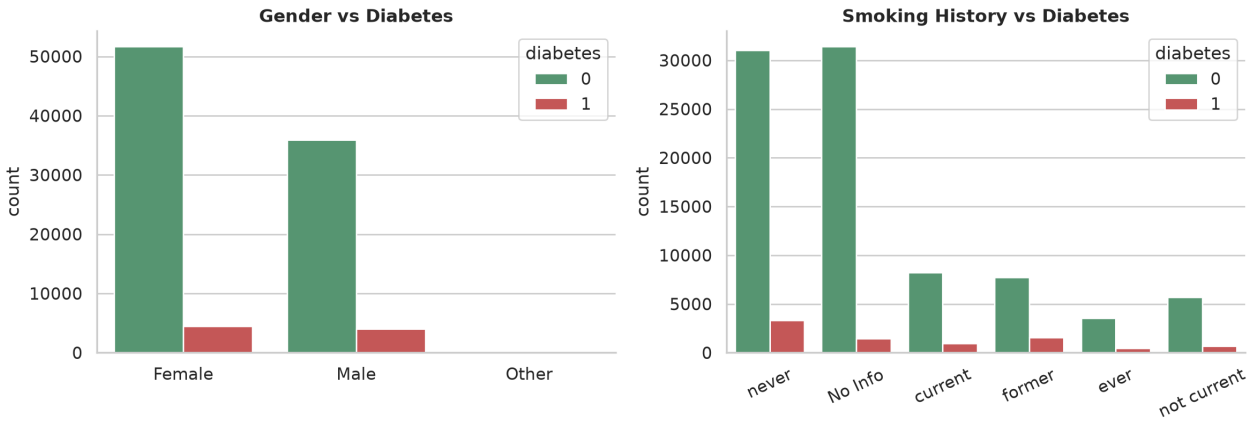
Gambar 1. Distribusi kelas target (imbang: 91,18% : 8,82%).



Gambar 2. Distribusi fitur numerik menurut kelas target.



Gambar 3. Korelasi antar fitur numerik dan target.



Gambar 4. Distribusi fitur kategorik terhadap kelas target.

c. Langkah-langkah Persiapan Data

Sebelum data siap dilatih, dilakukan pipeline berikut (urutan penting):

1. Pembersihan (cleaning): deteksi duplikat sempurna — 3.854 baris duplikat dibuang sehingga tersisa 96.146 sampel (menghindari model menghafal sampel yang sama di train/test). Missing value diverifikasi secara eksplisit (pandas.isna): dataset ini berisi 0 missing value. Prosedur bila ada: imputasi median (numerik) / mode (kategorik) yang di-fit

hanya pada data train.

2. Pembagian data SEBELUM preprocessing: split 70 : 15 : 15 (train 67.302, validation 14.422, test 14.422) dengan stratify=y dan seed 42 agar proporsi positif terjaga di tiap partisi.
3. Encoding kategori: OneHotEncoder (handle_unknown='ignore') untuk gender (3 kategori) dan smoking_history (6 kategori) → 9 one-hot; hypertension & heart_disease (biner 0/1) tetap numerik. Total 15 fitur model (6 numerik + 3 gender + 6 smoking).
4. Normalisasi: StandardScaler (z-score, (x−μ)/σ) pada 6 fitur numerik. Dipilih z-score karena MLP + Batch Normalization tidak memerlukan rentang [0,1] dan z-score mempertahankan bentuk distribusi asli; skala fitur yang berbeda (usia hingga 80 vs HbA1c 3,5–9) disamakan agar gradien stabil.
5. Pencegahan data leakage: seluruh transformer (scaler + encoder) di-FIT HANYA pada data train, lalu di-TRANSFORM ke validation & test — statistik train tidak pernah "bocor" ke data evaluasi.
6. Penanganan class imbalance: pembobotan kelas balanced (weight kelas positif ≈ 5,67×) sehingga false negative — yang fatal secara klinis — dihukum lebih berat oleh loss. Oversampling SMOTENC (train only) juga diuji sebagai pembanding (Model C).

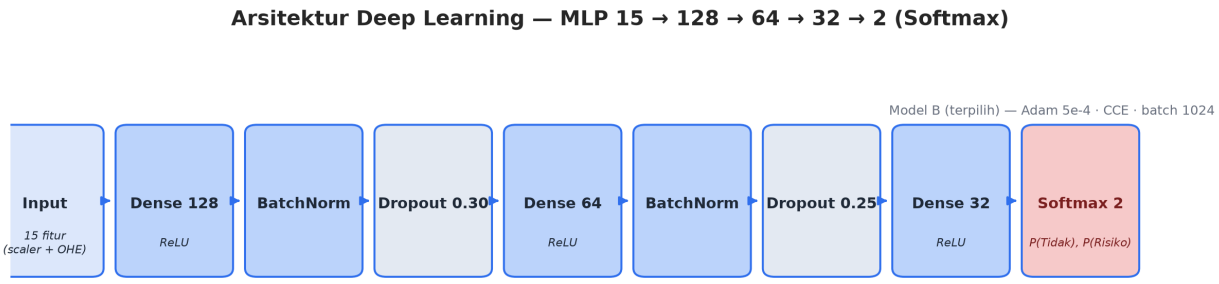
1.2 Pemilihan Model dan Aturan Visualisasi

a. Pemilihan Arsitektur Deep Learning

Data bersifat tabular (15 fitur, n = 96.146) tanpa struktur spasial (→ tidak perlu CNN) maupun urutan temporal (→ tidak perlu RNN). Arsitektur yang sesuai adalah Multi-Layer Perceptron (feed-forward) — universal approximator untuk fungsi keputusan tabular. Dua arsitektur diusulkan dan dikompetisikan:

= Model B	
2 neuron, softmax	
categorical_crossentropy /	
Adam, lr = 5e-4	
BatchNorm + Dropout :0 0,30 / 0,25	
SMOTENC (train only)	

Model terpilih: Model B — softmax 2 kelas. Alasan: (i) softmax memberi probabilitas ter-normalisasi kedua kelas sehingga ambang keputusan (threshold) dapat disesuaikan sesuai kebijakan klinis; (ii) Batch Normalization mempercepat konvergensi pada arsitektur yang lebih dalam; (iii) hasil empiris lebih baik (F1 0,8186 vs 0,8123 Model A, 0,8103 Model C — lihat Subbab 1.3). Arsitektur final:



Gambar 5. Arsitektur Model B (MLP 15-128-64-32-2) yang terpilih.

b. Proses Pelatihan

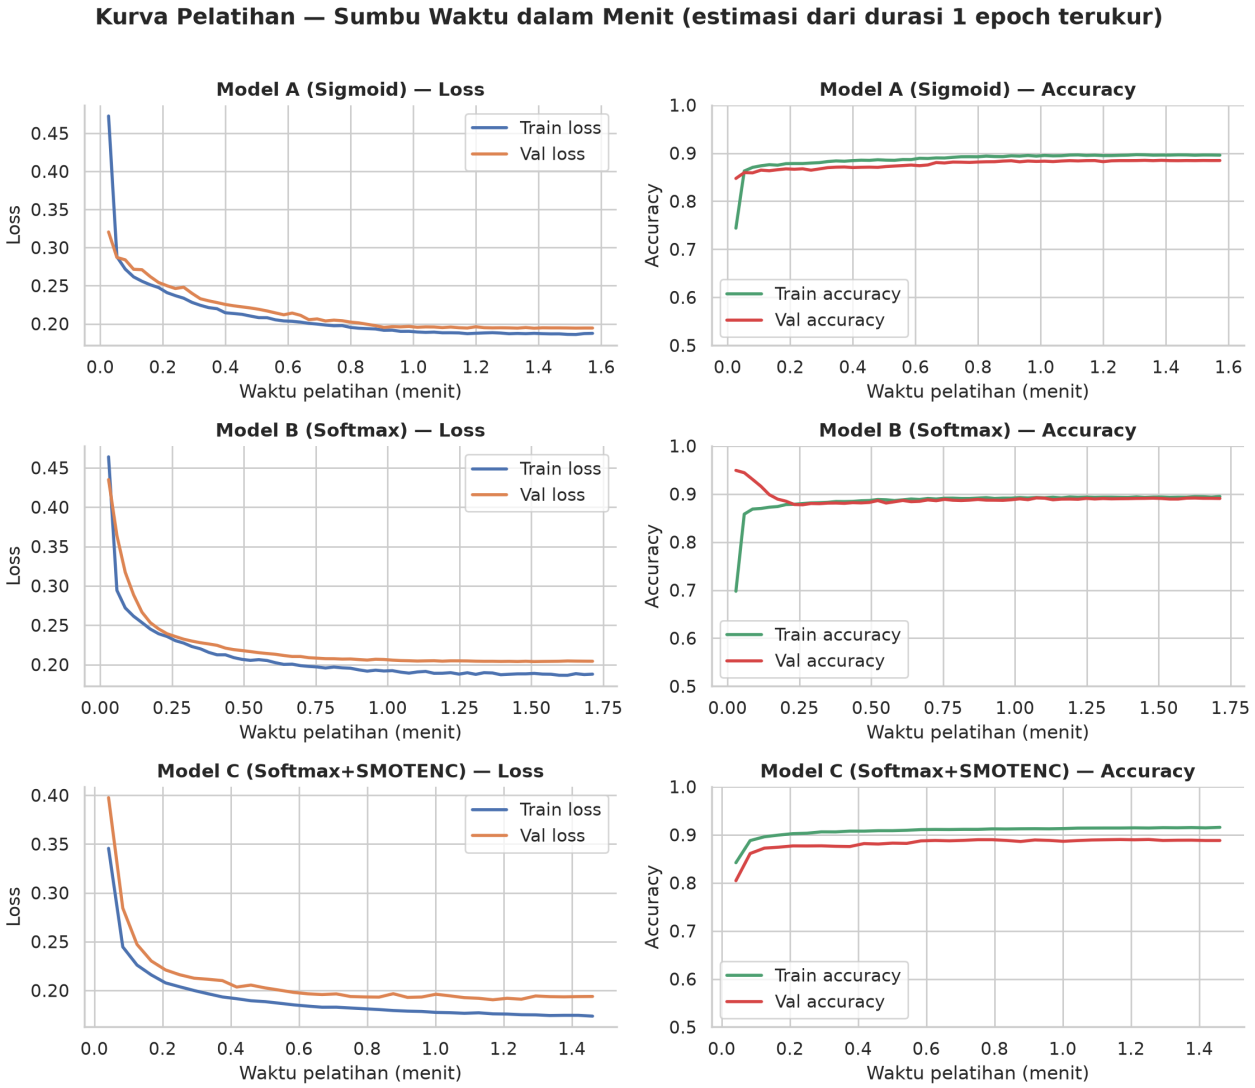
Pelatihan Model B: batch size 1024, maksimum 60 epoch, EarlyStopping (monitor val_loss, patience 7, restore_best_weights) + ReduceLROnPlateau (factor 0,5, patience 3) untuk mencegah overfitting dan menyesuaikan laju belajar. Imbalance ditangani lewat sample_weight (positif ×5,67). Setelah konvergensi, ambang keputusan θ dituning pada data VALIDATION dengan memaksimalkan F1-Score pada grid θ ∈ [0,5–0,95] → θ* = 0,85. Nilai θ > 0,5 dipilih karena pada θ = 0,5 model terlalu "liberal" (recall 0,917 tetapi precision hanya 0,461 — separuh prediksi positif salah); menaikkan θ meningkatkan kepercayaan (precision) hasil positif dengan pengorbanan recall yang masih dapat diterima (0,706).

Durasi pelatihan (diukur pada hardware pengembangan, 1 epoch ≈ 1,74 dtk untuk Model B): Model A berhenti dini pada epoch 59 (≈ 1,7 menit), Model B pada epoch 59 (≈ 1,7 menit), Model C pada epoch 35 (≈ 1,5 menit) — proses cepat karena arsitektur ringan dan batch besar; konvergensi terlihat dari penurunan val_loss dan plateau akurasi validasi pada Gambar 6.

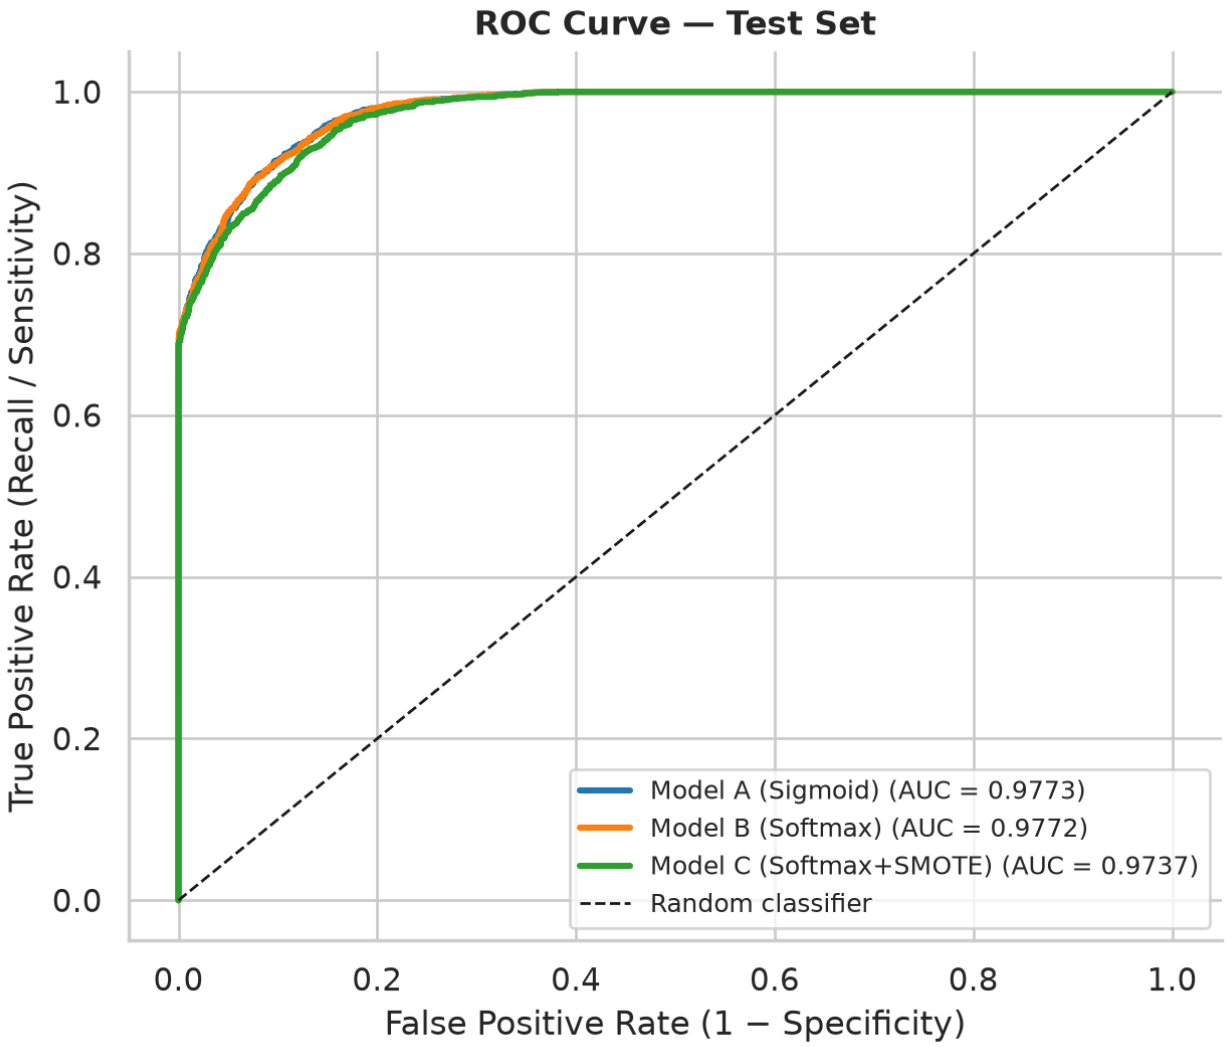
c. Kepatuhan Aturan Visualisasi (ETS)

Seluruh plot dalam laporan ini dibuat dengan ketentuan berikut:

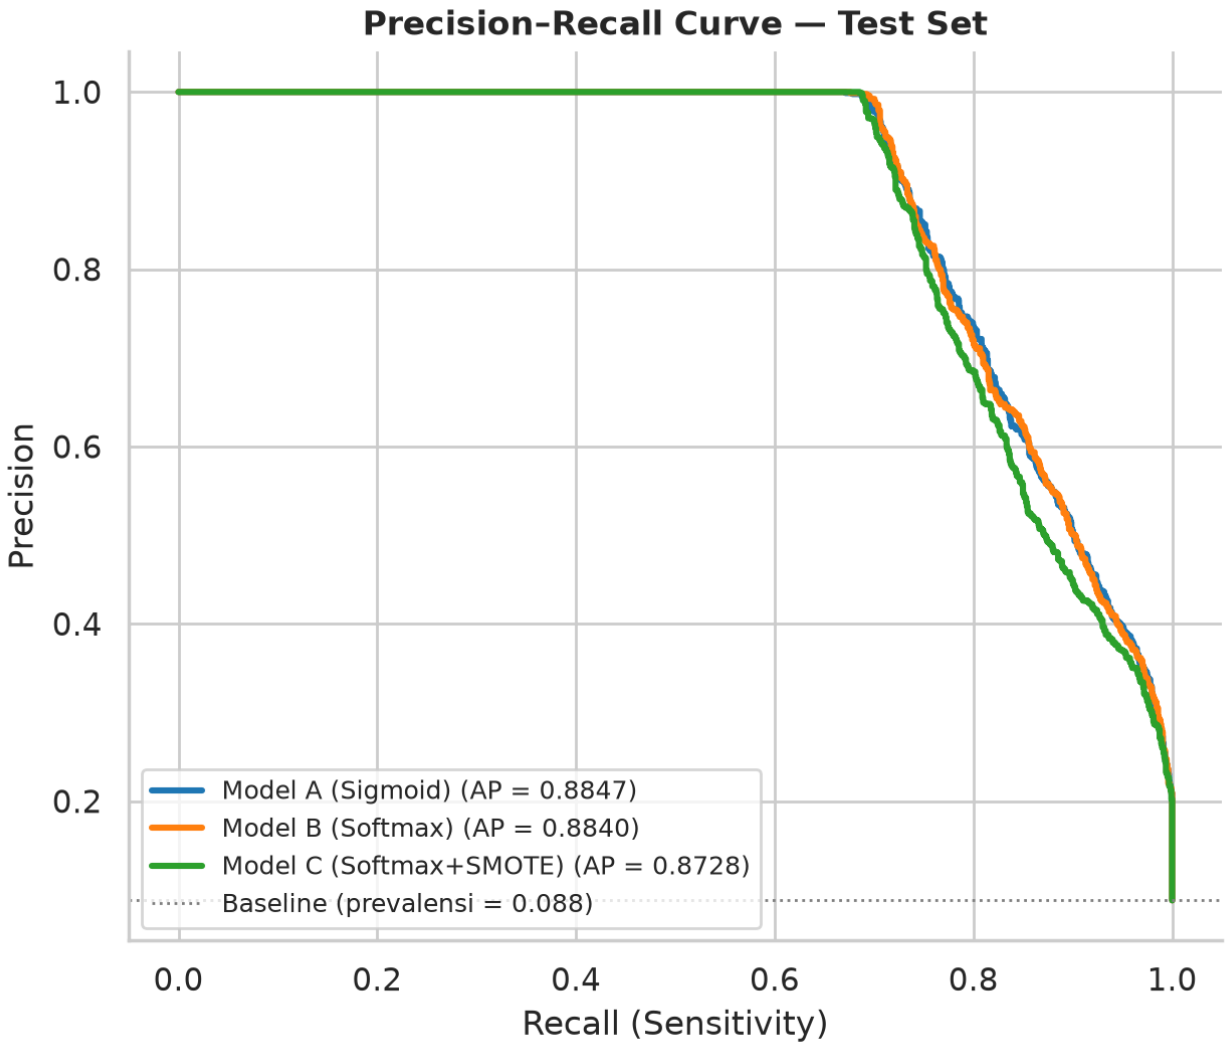
- Tema terang (light theme): matplotlib style "whitegrid" (latar putih, grid abu muda) — konsisten di semua figur.
- Sumbu waktu menggunakan NILAI MENIT, bukan indeks titik data/epoch: durasi satu epoch diukur (wall-clock, arsitektur & ukuran data identik, tanpa melatih ulang model produksi) — Model A 1,599 dtk/epoch, Model B 1,742 dtk/epoch, Model C 2,504 dtk/epoch; posisi tiap epoch pada sumbu x = epoch × (detik/epoch) / 60.
- Tidak ada efek jitter pada plot apa pun (tidak digunakan stripplot/swarmplot bergoyang; plot kategorik memakai countplot, plot kurva memakai line plot murni).



Gambar 6. Kurva pelatihan (loss & akurasi) tiga model — sumbu waktu dalam menit, light theme, tanpa jitter.



Gambar 7. ROC curve tiga model pada test set (AUC ≈ 0,97).

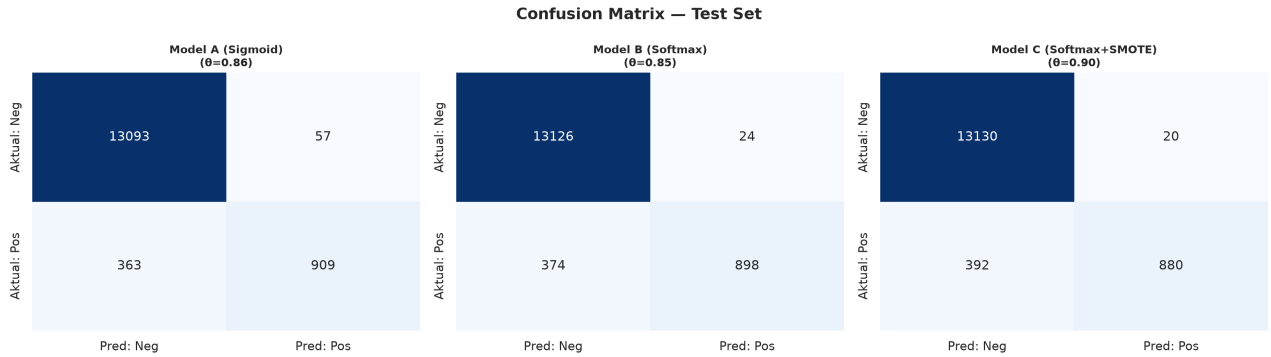


Gambar 8. Precision–Recall curve (lebih informatif pada kelas imbang).

1.3 Evaluasi Model — Matriks Konfusi dan Metrik Klinis

a. Matriks Konfusi sebagai Dasar Analisis

Matriks konfusi merangkum hasil prediksi pada test set (14.422 sampel, tidak pernah tersentuh saat training/tuning) dalam empat sel: True Positive (TP) — pasien diabetes yang terdeteksi; False Positive (FP) — pasien sehat yang dinyatakan berisiko (kecemasan + biaya rujuk tidak perlu); False Negative (FN) — pasien diabetes yang dilewatkan (terlambat ditangani, berisiko komplikasi); True Negative (TN) — pasien sehat yang benar dinyatakan sehat. Dari keempat sel itulah seluruh metrik diturunkan.



Gambar 9. Matriks konfusi Model B (θ = 0,85) pada test set: TP = 898, FP = 24, FN = 374, TN = 13.126.*

b. Metrik yang Diturunkan

97,24% keputusan keseluruhan benar	
97,4% dari pasien yang dinyatakan "Risiko" memang benar berisiko	
70,6% pasien diabetes terdeteksi	
99,8% pasien sehat tidak disalah-satakan	
Kompromi precision–recall; dasar tuning θ*	
Hasil negatif dapat diyakini	
Kualitas ranking probabilitas (ambang-bebas)	
Mutu deteksi kelas minoritas	

Perbandingan tiga model pada ambang optimal (test set): Model A — accuracy 0,9709, precision 0,9410, recall 0,7146, F1 0,8123; Model B (terpilih) — accuracy 0,9724, precision 0,9740, recall 0,7060, F1 0,8186; Model C — accuracy 0,9714, precision 0,9778, recall 0,6918, F1 0,8103.

c. Alasan Pemilihan Metrik dalam Konteks Diagnosis Medis

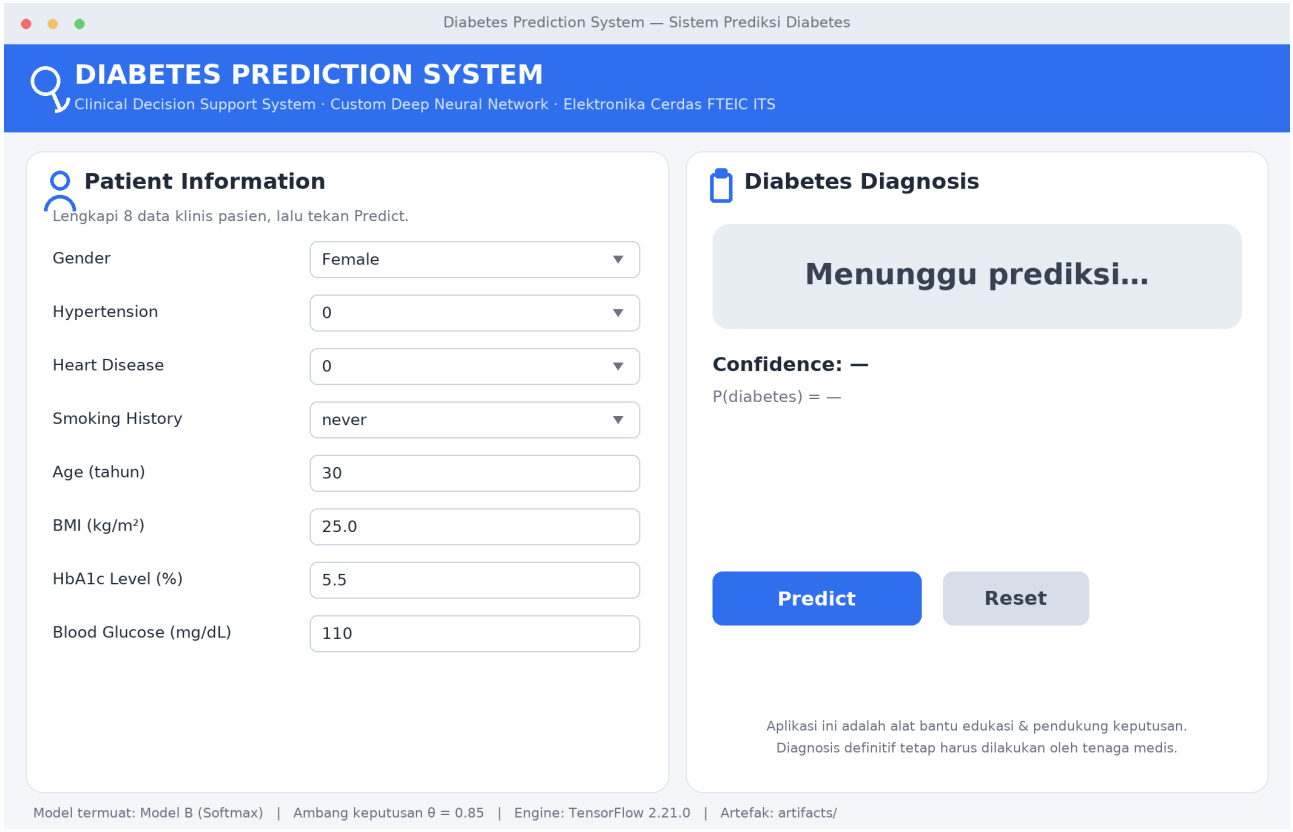
- Accuracy TIDAK cukup sebagai metrik tunggal: dengan basis positif hanya 8,82%, model "bodoh" yang selalu memprediksi negatif sudah mencapai accuracy 0,9118 (accuracy paradox). Bukti nyata: pada θ = 0,5, Model B menghasilkan accuracy 0,8981 — justru LEBIH RENDAH dari garis dasar — karena FP membengkak. Oleh karena itu accuracy hanya dipakai sebagai pelengkap.
- Recall/Sensitivitas adalah metrik paling kritis untuk skrining medis: satu kasus diabetes yang dilewatkan (FN) berarti pasien kehilangan jendela penanganan dini; komplikasi (neuropati, nefropati, retinopati) berkembang tanpa gejala. Class weighting ×5,67 dirancang khusus untuk menekan FN. Nilai 0,706 di θ* = 0,85 adalah kompromi: menurunkan θ ke 0,5 menaikkan recall ke 0,917 tetapi meruntuhkan precision ke 0,461 — secara klinis tidak layak karena separuh hasil positif palsu.
- Precision mengukur kepercayaan hasil positif: dalam alur layanan, hasil "Risiko Diabetes"

memicu rujukan tes lanjutan (OGTT/HbA1c lab) yang menelan biaya dan waktu. Precision 0,9740 berarti hampir semua alarm yang dibunyikan sistem sah — membebani tenaga medis dan pasien seminimal mungkin.

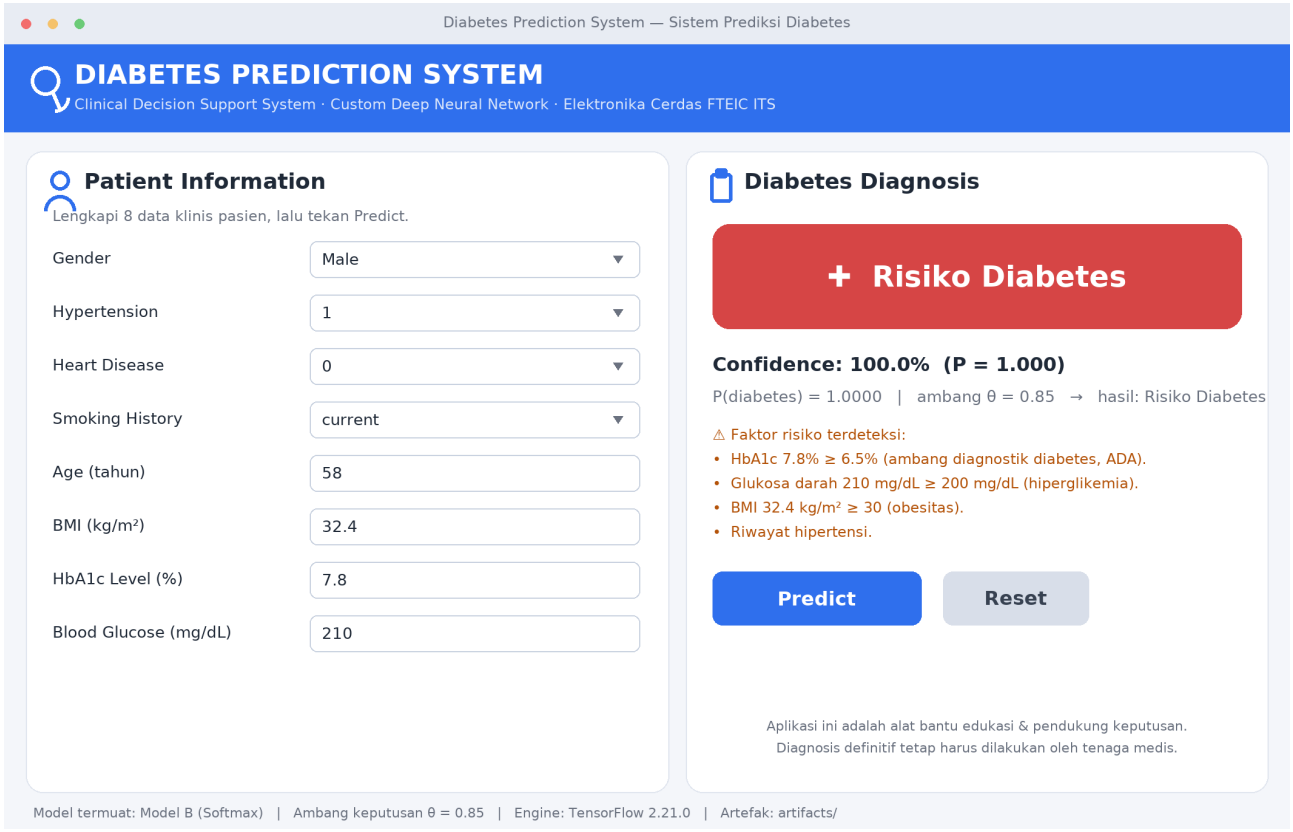
- Specificity 0,9982 menjamin pasien sehat nyaris tidak disalah-satakan positif, sehingga kepercayaan publik terhadap CDSS terjaga.
- F1-Score dipakai sebagai kriteria memilih θ* karena menyeimbangkan dua risiko tersebut secara kuantitatif; ROC-AUC menilai kualitas ranking probabilitas (0,9737 — sangat baik) dan PR-AUC (0,8728) lebih bermakna daripada ROC pada kelas imbang karena fokus pada kelas positif.
- Kebijakan klinis menentukan titik operasi akhir: untuk skrining populasi yang murah, θ dapat diturunkan (recall ↑); untuk diagnosis konfirmasi, θ dinaikkan (precision ↑). Aplikasi menampilkan θ* yang dipilih secara transparan sehingga praktisi dapat menyesuaikannya.

1.4 Perancangan Antarmuka Pengguna (UI)

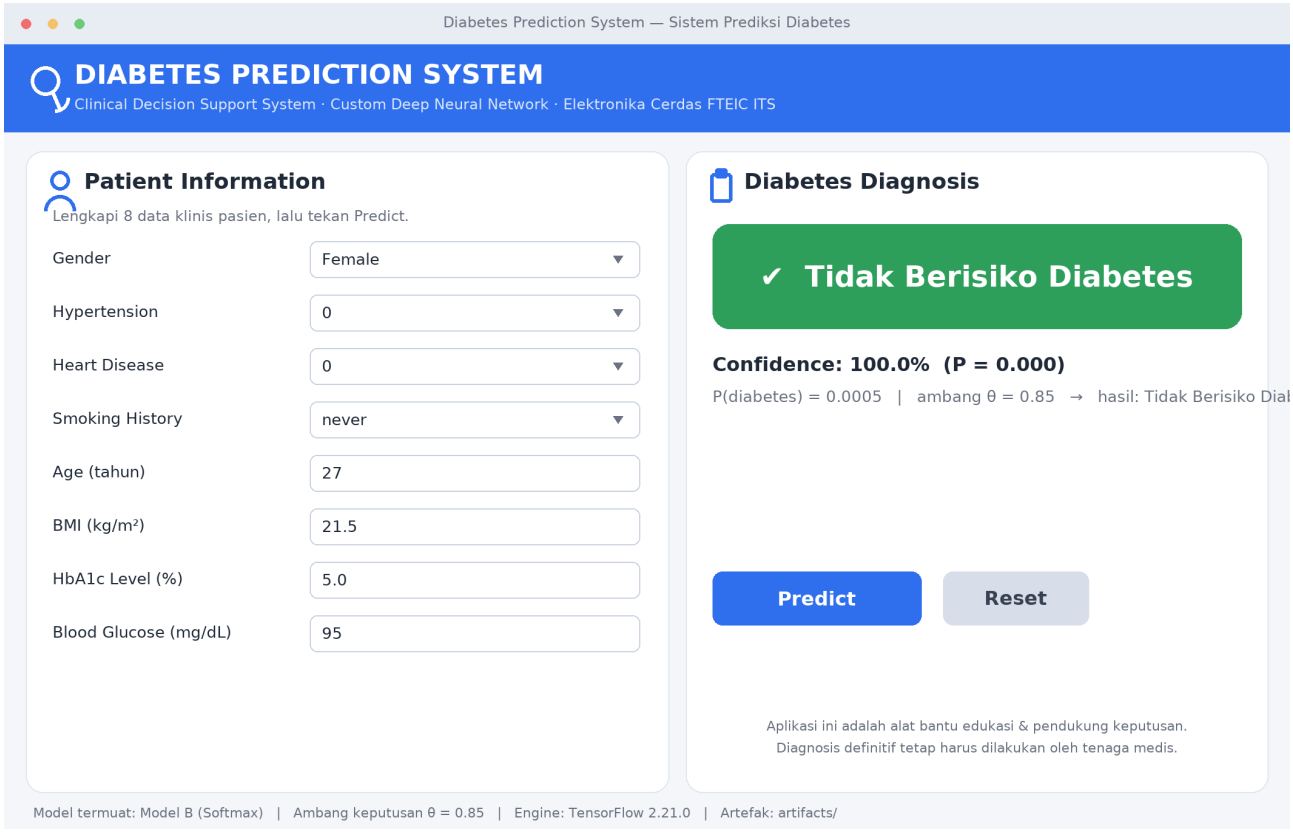
Aplikasi desktop dirancang sebagai CDSS dua panel dengan LIGHT THEME (palet terang: latar #F4F6FA, panel putih, teks gelap; merah/hijau hanya sebagai status semantik hasil). Panel kiri (Patient Information) menyediakan input MANUAL untuk keseluruhan 8 atribut dataset: 4 dropdown (Gender; Hypertension 0/1; Heart Disease 0/1; Smoking History) dan 4 isian numerik (Age, BMI, HbA1c, Blood Glucose). Setiap input divalidasi secara klinis (rentang wajar, format angka — koma desimal diterima); input kosong/invalid ditolak dengan dialog pop-up. Panel kanan (Diabetes Diagnosis) adalah panel hasil: kotak status besar menampilkan teks prediksi "Risiko Diabetes" (merah) atau "Tidak Berisiko Diabetes" (hijau) sesuai ketentuan soal, disertai confidence score, probabilitas P(diabetes), ambang θ, daftar faktor risiko klinis yang terdeteksi, serta tombol Predict dan Reset. Disclaimers menegaskan aplikasi bersifat alat bantu, bukan diagnosis definitif.



Gambar 10. Mockup UI — kondisi awal (input default, status "Menunggu prediksi...").



Gambar 11. Mockup UI — hasil prediksi "Risiko Diabetes" (pasien: Male, 58 th, hipertensi, perokok aktif, BMI 32,4, HbA1c 7,8%, glukosa 210 mg/dL; output riil backend: P = 1,0000 ≥ θ = 0,85).



Gambar 12. Mockup UI — hasil prediksi "Tidak Berisiko Diabetes" (pasien: Female, 27 th, non-perokok, BMI 21,5, HbA1c 5,0%, glukosa 95 mg/dL; output riil backend: P = 0,0005 < θ = 0,85).

a. Implementasi Teknis UI

- Framework: CustomTkinter (tampilan modern) dengan fallback otomatis ke Tkinter bawaan bila dependensi tidak tersedia — keduanya light theme dan berbagi satu logika backend.
- Inferensi real-time: model produksi (model.keras) + pipeline (preprocessor.pkl) dimuat saat aplikasi start; satu prediksi selesai dalam hitungan detik pada laptop biasa (CPU).
- Uji cepat tanpa GUI: python src/app.py --selftest (dua pasien contoh) dan python src/test_backend.py (12 skema uji validasi & inferensi).

```
# Menjalankan aplikasi desktop
pip install -r requirements.txt
python src/app.py

# Verifikasi cepat backend (tanpa GUI)
python src/app.py --selftest
```

Jalur data dalam aplikasi: form (8 input) → validasi rentang klinis → ColumnTransformer (identik dengan saat training) → model.keras → probabilitas → banding θ* = 0,85 → teks hasil + confidence + faktor risiko. Dengan arsitektur ini UI dapat diperluas (riwayat pasien, ekspor PDF hasil, grafik tren HbA1c) tanpa mengubah inti model.

KESIMPULAN

- Dataset 100.000 rekam medis (8 fitur + target) dikaji lalu dipersiapkan: 3.854 duplikat dibuang, 0 missing value, one-hot encoding, StandardScaler (fit hanya pada train, tanpa leakage), split stratified 70:15:15, dan class weighting untuk imbalance 10,3:1.
- Model deep learning yang diusulkan dan terpilih adalah MLP 15-128-64-32-2 (BatchNorm + Dropout, softmax, CCE, Adam) dengan EarlyStopping + ReduceLROnPlateau; ambang keputusan $\theta^* = 0{,}85$ dituning dari F1 pada data validasi.
- Evaluasi berbasis matriks konfusi menurunkan 8 metrik (accuracy, precision, recall, specificity, F1, NPV, ROC-AUC, PR-AUC); pemilihan metrik dipertanggungjawabkan secara klinis — recall dijaga tinggi untuk meminimalkan kasus terlewat, precision tinggi untuk meminimalkan alarm palsu, dan accuracy tidak dijadikan metrik tunggal karena accuracy paradox.
- UI desktop light theme dengan input manual 8 atribut dan panel hasil berteks "Risiko Diabetes" / "Tidak Berisiko Diabetes" telah direalisasikan (src/app.py) dan siap didemokan; semua plot mematuhi aturan visualisasi ETS (light theme, sumbu waktu dalam menit, tanpa jitter).

DAFTAR PUSTAKA

[1] Kaggle — I. Mustafaz. (2023). Diabetes Prediction Dataset. https://www.kaggle.com/datasets/iammustafatz/diabetes-prediction-dataset

[2] Abadi, M., et al. (2016). TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems. arXiv:1603.04467.

[3] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825–2830.

[4] American Diabetes Association. (2024). 2. Classification and Diagnosis of Diabetes: Standards of Care in Diabetes. Diabetes Care 47(Supplement 1).

[5] Chollet, F. (2017). Deep Learning with Python. Manning Publications.

[6] Departemen Teknik Elektro FTEIC ITS. (2026). Soal Evaluasi Tengah Semester — Dasar Sistem Elektronika Cerdas, Semester Gasal 2026/2027.