

ELEKTRONIKA CERDAS · SEMESTER GASAL 2026/2027

LAPORAN TUGAS PROYEK PREDIKSI PENYAKIT DIABETES

Clinical Decision Support System Berbasis Custom Deep Neural Network dengan Aplikasi Desktop

Dataset: Kaggle — Diabetes Prediction Dataset (100.000 rekam medis)

Engine: TensorFlow (Keras) · GUI: CustomTkinter / Tkinter

Nama :
NRP :

DEPARTEMEN TEKNIK ELEKTRO
FAKULTAS TEKNIK ELEKTRO, INFORMATIKA, DAN INTELIJEN — FTEIC
INSTITUT TEKNOLOGI SEPULUH NOPEMBER
2026

RINGKASAN EKSEKUTIF

Proyek ini membangun sistem pendukung keputusan klinis (Clinical Decision Support System) untuk memprediksi risiko diabetes mellitus dari 8 fitur rekam medis pasien. Dataset Kaggle berisi 100.000 sampel dibersihkan (3.854 baris duplikat dibuang) lalu dibagi 70:15:15 secara stratified menjadi data Train / Validation / Test. Seluruh transformer preprocessing (StandardScaler + OneHotEncoder) di-fit hanya pada data train sehingga tidak terjadi kebocoran data (data leakage). Ketidakseimbangan kelas 91,5 % : 8,5 % ditangani dengan pembobotan kelas balanced dan penyesuaian ambang keputusan (decision threshold tuning) berbasis F1-Score pada data validasi.

Dua arsitektur custom Multi-Layer Perceptron dibandingkan: Model A (output sigmoid, binary_crossentropy, Dropout) dan Model B (output softmax 2-neuron, categorical_crossentropy, BatchNormalization + Dropout, lebih dalam dan lebih lebar, learning rate lebih kecil). Pada Test Set dengan ambang optimal, Model B (Softmax) unggul dengan Accuracy 97,24 %, Precision 97,40 %, Recall 70,60 %, F1-Score 0,8186, dan ROC-AUC 0,9772, sehingga dipilih sebagai model produksi. Model diekspor ke model.keras beserta preprocessor.pkl, lalu diintegrasikan ke aplikasi desktop "Diabetes Prediction System" (CustomTkinter) yang melakukan inferensi real-time dengan transformasi pipeline yang identik dengan proses training.

BAB 1 PENDAHULUAN

1.1 Latar Belakang


Diabetes mellitus adalah penyakit kronis dengan prevalensi yang terus meningkat dan berisiko fatal bila terdeteksi lambat. Sistem pendukung keputusan klinis berbasis machine learning dapat membantu tenaga medis melakukan skrining awal: dari 8 fitur rekam medis (gender, usia, hipertensi, penyakit jantung, riwayat merokok, BMI, kadar HbA1c, dan glukosa darah) model memperkirakan probabilitas pasien menderita diabetes. Proyek ini membangun sistem tersebut secara end-to-end — dari data mentah, pelatihan custom deep neural network, hingga aplikasi desktop dengan GUI.

1.2 Tujuan

1. Membangun pipeline preprocessing data klinis yang bebas kebocoran data (no data leakage) serta menangani class imbalance secara tepat.
2. Merancang, melatih, dan membandingkan minimal dua arsitektur custom MLP yang bervariasi (kedalaman, lebar, regularisasi, learning rate).
3. Mengimplementasikan dan mengkomparasi formulasi output layer Sigmoid vs Softmax beserta loss function yang sesuai, dengan justifikasi teoretis dan empiris.
4. Mengevaluasi model dengan metrik klinis lengkap: Accuracy, Precision, Recall, F1-Score, Confusion Matrix, ROC dan PR Curve.
5. Mengintegrasikan model terlatih + pipeline preprocessing ke aplikasi desktop (CustomTkinter) untuk inferensi real-time.

1.3 Arsitektur Sistem End-to-End

Alur kerja sistem mengikuti 8 tahap: (1) Dataset Kaggle 100k records → (2) Preprocessing: cleaning, encoding, StandardScaler tanpa leakage → (3) Pemodelan: Model A vs Model B, Sigmoid vs Softmax, regularisasi & tuning → (4) Evaluasi: Accuracy, Precision, Recall, F1, Confusion Matrix → (5) Serialisasi: model.keras + preprocessor.pkl → (6) GUI Desktop CustomTkinter → (7) Integrasi logika inferensi real-time dengan objek scaler/encoder → (8) Hasil prediksi klinis & tampilan diagnosis.



Gambar 1.1 Distribusi kelas target: 91,5 % negatif vs 8,5 % positif — tantangan class imbalance (Accuracy Paradox).

BAB 2 DATASET & PREPROCESSING

2.1 Deskripsi Dataset

Dataset publik Kaggle "Diabetes Prediction Dataset" berisi 100.000 sampel rekam medis dengan 8 fitur prediktor dan 1 target biner. Rincian fitur:


Fitur	Tipe	Rentang / Kategori	Perlakuan Preprocessing
gender	Kategorik	Female, Male, Other	OneHotEncoder
age	Numerik	0,08 – 80,0 tahun	StandardScaler
hypertension	Biner	0 / 1	StandardScaler (indikator)
heart_disease	Biner	0 / 1	StandardScaler (indikator)
smoking_history	Kategorik	6 kategori (incl. No Info)	OneHotEncoder
bmi	Numerik	10,01 – 95,69 kg/m²	StandardScaler
HbA1c_level	Numerik	3,5 – 9,0 %	StandardScaler
blood_glucose_level	Numerik	80 – 300 mg/dL	StandardScaler
diabetes (target)	Biner	0 = negatif, 1 = positif	—

2.2 Pembersihan Data (Cleaning)


- Missing value: tidak ditemukan satu pun nilai kosong pada seluruh 100.000 baris, sehingga imputasi tidak diperlukan (diverifikasi dengan `df.isna().sum()`).
- Duplikasi: ditemukan 3.854 baris duplikat sempurna dan dibuang (`drop_duplicates`) agar sampel identik tidak bocor antar partisi split — ukuran akhir 96.146 sampel.
- Kategori 'Other' pada gender (18 sampel) tetap dipertahankan sebagai kategori tersendiri oleh OneHotEncoder.



Gambar 2.1 Distribusi fitur numerik per kelas: HbA1c dan glukosa darah kelas positif bergeser jauh ke kanan (pemisah terkuat).



Gambar 2.2 Heatmap korelasi: HbA1c_level ↔ diabetes ≈ 0,56 dan blood_glucose_level ↔ diabetes ≈ 0,55 — dominan dibanding fitur lain.



Gambar 2.3 Distribusi fitur kategorik terhadap kelas target.

2.3 Pembagian Data — Train / Validation / Test (70 : 15 : 15, Stratified)

Split dilakukan dengan dua kali `train_test_split` (70/30 lalu 15/15) menggunakan `stratify=y` agar proporsi kelas positif $\pm 8,8\%$ terjaga di setiap partisi. Split dilakukan SEBELUM preprocessing apa pun.

Partisi	Jumlah Sampel	Proporsi	p(diabetes=1)
Train	67.302	70,0 %	0,0882
Validation	14.422	15,0 %	0,0883
Test	14.422	15,0 %	0,0882

2.4 Pipeline Preprocessing & Pencegahan Data Leakage

Preprocessing memakai `ColumnTransformer` Scikit-Learn: `StandardScaler` untuk 6 kolom numerik dan `OneHotEncoder(handle_unknown='ignore')` untuk 2 kolom kategorik. Setelah one-hot, dimensi fitur model menjadi 15 (6 numerik + 3 gender + 6 smoking).

Kaidah kritis pencegahan kebocoran data: `preprocessor.fit()` dipanggil HANYA pada data Train; data Validation dan Test hanya menerima `transform()`. Dengan demikian statistik train (mean/std scaler, daftar kategori encoder) tidak pernah melihat data evaluasi. Objek `preprocessor` yang sama diserialisasi ke `preprocessor.pkl` sehingga aplikasi desktop memakai transformasi yang identik dengan proses training.

```
preprocessor = ColumnTransformer([
    ('num', StandardScaler(), NUM_FEATURES),
    ('cat', OneHotEncoder(handle_unknown='ignore', sparse_output=False), CAT_FEATURES),
])
preprocessor.fit(X_train)          # FIT hanya pada TRAIN
X_train_pp = preprocessor.transform(X_train)
X_val_pp   = preprocessor.transform(X_val)   # transform saja
X_test_pp  = preprocessor.transform(X_test)  # transform saja
```

2.5 Penanganan Class Imbalance

Rasio kelas negatif : positif = 10,34 : 1. Model naif yang selalu memprediksi 0 memperoleh akurasi 91,5 % tanpa mendeteksi satu pun pasien diabetes (Accuracy Paradox). Dua mitigasi diterapkan:

- Class weighting 'balanced' — dihitung hanya dari data train: bobot kelas 0 = 0,5484 dan kelas 1 = 5,6680. Model A menerimanya lewat `class_weight`; Model B (label one-hot) lewat `sample_weight` yang ekuivalen secara matematis.

- Decision threshold tuning — ambang klasifikasi θ dioptimalkan pada data VALIDATION dengan memaksimalkan F1-Score kelas positif (grid $\theta \in [0,10; 0,90]$), lalu ambang terbaik diterapkan pada Test Set. Default $\theta = 0,5$ tidak cocok karena pembobotan kelas menggeser distribusi probabilitas model.

Metrik akurasi TIDAK dijadikan acuan utama: evaluasi berfokus pada Recall (sensitivitas — menghindari False Negative yang fatal secara medis), Precision, F1-Score, Confusion Matrix, serta ROC/PR Curve.

BAB 3 ARSITEKTUR MODEL — SIGMOID VS SOFTMAX

3.1 Desain Dua Arsitektur Custom MLP

Kedua model dibangun dari awal (Sequential/Functional Keras) dengan variasi kedalaman, lebar, regularisasi, dan learning rate sesuai spesifikasi tugas. Callback: EarlyStopping(patience=7, restore_best_weights) dan ReduceLROnPlateau(factor=0,5, patience=3). Batch size 1024, maksimal 60 epoch; keduanya konvergen stabil hingga epoch 59 dengan best validation loss 0,194 (A) dan 0,204 (B). Seed global 42 untuk reproducibility.

Aspek	Model A — Sigmoid	Model B — Softmax
Topologi	15 → 64 → 32 → 1	15 → 128 → 64 → 32 → 2
Kedalaman (hidden)	2 layer	3 layer (lebih dalam)
Lebar maksimum	64 neuron	128 neuron (lebih lebar)
Regularisasi	Dropout 0,30 / 0,20	BatchNorm + Dropout 0,30 / 0,25
Aktivasi output	Sigmoid (1 neuron)	Softmax (2 neuron)
Loss	binary_crossentropy	categorical_crossentropy
Format label	Skalar $y \in \{0, 1\}$	One-hot $y \in \{[1,0],[0,1]\}$
Optimizer / LR awal	Adam, $lr = 1 \times 10^{-3}$	Adam, $lr = 5 \times 10^{-4}$
LR scheduling	ReduceLROnPlateau	ReduceLROnPlateau
Imbalance handling	class_weight	sample_weight (ekuivalen)

3.2 Formulasi Matematis Output Layer

Opsi A — Sigmoid

Satu neuron output: $\sigma(z) = 1 / (1 + e^{(-z)}) \in [0, 1]$, diinterpretasikan sebagai $P(\text{diabetes})$. Loss binary_crossentropy per sampel: $L_{\text{BCE}} = -[y \cdot \ln(\hat{y}) + (1-y) \cdot \ln(1-\hat{y})]$. Keputusan: $\hat{y} \geq \theta \rightarrow \text{Positif}$.

Opsi B — Softmax

Dua neuron output: $P(y=i | z) = e^{(z_i)} / \sum_j e^{(z_j)}$, $i \in \{0,1\}$, menghasilkan distribusi probabilitas penuh (P_0, P_1). Loss categorical_crossentropy: $L_{\text{CCE}} = -\sum_i y_i \cdot \ln(\hat{y}_i)$. Keputusan: $\text{argmax}(P_0, P_1)$ atau $P_1 \geq \theta$. Untuk kasus biner, kedua formulasi ekuivalen secara teoretis; perbandingan empiris pada Bab 4 menentukan pilihan akhir.


3.3 Justifikasi Pemilihan Arsitektur

Model A mewakili desain ringan (dangkal, sempit, dropout murni) dengan learning rate relatif besar; Model B mewakili desain dalam-lebar dengan Batch Normalization untuk stabilitas gradien dan learning rate lebih kecil. Perbedaan desain ini disengaja agar komparasi Bab 4 menjawab pertanyaan: apakah kapasitas dan regularisasi ekstra sepadan, serta formulasi output mana yang lebih baik pada data timpang ini?

BAB 4 HASIL EVALUASI & SELEKSI MODEL

4.1 Decision Threshold Tuning (Data Validation)

Karena pembobotan kelas menggeser distribusi probabilitas, ambang default 0,5 bukan pilihan terbaik. Sweep θ pada data validasi menghasilkan $\theta^* = 0,86$ untuk Model A dan $\theta^* = 0,85$ untuk Model B (F1 validasi 0,790 untuk keduanya). Ambang inilah yang disimpan ke `preprocessor.pkl` dan dipakai aplikasi desktop.




Gambar 4.1 Sweep ambang keputusan pada data Validation: F1-Score kelas positif vs θ untuk kedua model.

4.2 Metrik Klinis pada Test Set

Metrik	Model A $\theta=0,50$	Model A $\theta^*=0,86$	Model B $\theta=0,50$	Model B $\theta^*=0,85$
Accuracy	0,8954	0,9709	0,8981	0,9724
Precision	0,4544	0,9410	0,4611	0,9740
Recall (Sensitivitas)	0,9237	0,7146	0,9167	0,7060
F1-Score	0,6091	0,8123	0,6135	0,8186
ROC-AUC	0,9773	0,9773	0,9772	0,9772
PR-AUC (AP)	0,8847	0,8847	0,8840	0,8840

Tanpa tuning ($\theta=0,5$) kedua model sangat sensitif ($\text{Recall} > 0,91$) tetapi precision rendah ($\pm 0,46$): hampir separuh alarm positif adalah palsu. Dengan ambang optimal, precision melonjak ke 0,94–0,97 dengan recall tetap 0,71 — titik operasi yang sehat untuk alat skrining pendamping tenaga medis. Pemilihan θ dapat digeser sesuai kebijakan klinis: turunkan θ bila sensitivitas harus diprioritaskan.


4.3 Confusion Matrix (Test Set, θ^*)




Gambar 4.2 Confusion Matrix kedua model pada Test Set (14.422 sampel).

Model	TN	FP	FN	TP
Model A (Sigmoid, $\theta=0,86$)	13.093	57	363	909
Model B (Softmax, $\theta=0,85$)	13.126	24	374	898


4.4 ROC & Precision-Recall Curve



Gambar 4.3 ROC Curve: kedua model hampir identik ($AUC \approx 0,977$).

Gambar 4.4 Precision-Recall Curve: AP $\approx$ 0,884 — jauh di atas baseline prevalensi 0,088.

4.5 Riwayat Pelatihan



Gambar 4.5 Kurva loss & akurasi train/validation: konvergensi stabil tanpa overfitting signifikan (gap train-val kecil).

4.6 Seleksi Model Terbaik

Kriteria seleksi utama: F1-Score kelas positif pada Test Set dengan ambang optimal (metrik paling informatif untuk data timpang), ROC-AUC sebagai pembanding. Hasil: Model B (Softmax) unggul tipis namun konsisten — F1 0,8186 vs 0,8123, Precision 0,9740 vs 0,9410, Accuracy 0,9724 vs 0,9709, dengan jumlah False Positive hanya setengah dari Model A (24 vs 57). ROC-AUC keduanya praktis identik

(0,9772 vs 0,9773).

Justifikasi output layer: secara teoretis sigmoid dan softmax ekuivalen untuk klasifikasi biner; secara empiris pada proyek ini arsitektur softmax dengan BatchNormalization dan kapasitas lebih besar menghasilkan kalibrasi keputusan yang sedikit lebih baik (precision tertinggi, FP terendah) sehingga Model B ditetapkan sebagai model produksi. Model B diekspor ke artifacts/model.keras bersama ambang $\theta^* = 0,85$ di preprocessor.pkl.

Catatan klinis: recall 0,706 berarti $\pm 29\%$ kasus positif lolos skrining pada titik operasi ini. Dalam praktik, hasil aplikasi harus selalu dikonfirmasi tes diagnostik (FPG/OGTT/HbA1c lab), dan θ dapat diturunkan bila sensitivitas lebih diprioritaskan.

BAB 5 INTEGRASI SISTEM & APLIKASI DESKTOP

5.1 Artefak Serialisasi

- artifacts/model.keras — arsitektur + bobot Model B terlatih (dimuat dengan `tf.keras.models.load_model`).
- artifacts/preprocessor.pkl — bundle joblib berisi: objek ColumnTransformer (StandardScaler + OneHotEncoder hasil fit data train), daftar urutan 15 fitur, ambang optimal θ^* , mode output ('softmax'), dan metadata model.
- artifacts/training_history.json — riwayat loss/akurasi, bobot kelas, dan seluruh metrik untuk reproduktibilitas laporan.

5.2 Alur Inferensi GUI (Fase III)

1. Saat aplikasi dimulai, `src/app.py` melokalisasi folder artifacts/, memuat model.keras dan preprocessor.pkl, lalu menampilkan nama model dan ambang pada status bar.
2. Pengguna mengisi 8 kontrol input (4 dropdown kategorik + 4 entry numerik) pada panel kiri "Patient Information".
3. Tombol Predict memicu validasi input: field kosong, nilai non-numerik, dan nilai di luar rentang klinis wajar ditolak dengan dialog pop-up informatif — aplikasi tidak pernah crash karena input salah.
4. Input valid disusun menjadi DataFrame dengan urutan kolom identik saat training, ditransformasi preprocessor.pkl (scaler + encoder yang sama persis), lalu diumpankan ke model.
5. Probabilitas $P(\text{diabetes})$ dibandingkan $\theta^* = 0,85$; panel kanan "Diabetes Diagnosis" menampilkan status berwarna (MERAH = Positive/Diabetic, HIJAU = Negative/Non-Diabetic), confidence score, probabilitas, dan daftar faktor risiko klinis yang terdeteksi (mis. $\text{HbA1c} \geq 6,5 \%$).
6. Tombol Reset mengembalikan form ke kondisi awal dan mengosongkan panel hasil.

5.3 Hasil Uji Integrasi

Skenario Pasien	Input Utama	$P(\text{diabetes})$	Keputusan GUI
Sehat	Female, 27 th, BMI 21,5, HbA1c 5,0 %, glukosa 95	0,0005	NEGATIVE (hijau)
Berisiko tinggi	Male, 58 th, hipertensi, perokok aktif, BMI 32,4, HbA1c 7,8 %, glukosa 210	1,0000	POSITIVE (merah)
Default form	Female, 30 th, BMI 25,0, HbA1c 5,5 %, glukosa 110	0,090	NEGATIVE (hijau)

Seluruh skenario diverifikasi otomatis oleh `src/test_backend.py` (uji validasi input, inferensi kedua pasien contoh, dan penanganan error) serta smoke test GUI pada kedua varian antarmuka (CustomTkinter dan fallback Tkinter).

BAB 6 PANDUAN INSTALASI & PENGOPERASIAN (USER GUIDE)

6.1 Kebutuhan Sistem

- Python 3.9 atau lebih baru (disarankan 3.10–3.12).
- Paket: tensorflow, pandas, numpy, scikit-learn, joblib, matplotlib, seaborn, customtkinter (GUI; bila tidak ada, aplikasi otomatis memakai Tkinter bawaan).
- Sistem operasi apa pun dengan tampilan grafis (Windows / macOS / Linux).

6.2 Instalasi

```
# 1. ekstrak berkas ZIP tugas ke sebuah folder
# 2. buat virtual environment (disarankan)
python -m venv .venv
.venv\Scripts\activate      # Windows
source .venv/bin/activate   # macOS/Linux

# 3. pasang dependensi
pip install -r requirements.txt

# 4. jalankan aplikasi desktop
python src/app.py
```

6.3 Mengoperasikan Aplikasi

1. Buka aplikasi — jendela "Diabetes Prediction System" muncul dengan panel kiri "Patient Information" dan panel kanan "Diabetes Diagnosis". Status bar menampilkan model dan ambang θ yang aktif.
2. Pilih nilai dropdown: Gender (Female/Male/Other), Hypertension (0/1), Heart Disease (0/1), Smoking History (never/current/former/ever/not current/No Info).
3. Ketik nilai numerik: Age (tahun), BMI (kg/m^2), HbA1c Level (%), Blood Glucose (mg/dL). Koma maupun titik desimal diterima.
4. Tekan Predict — panel kanan menampilkan diagnosis: teks besar merah (POSITIVE — DIABETIC) atau hijau (NEGATIVE — NON-DIABETIC), confidence score (%), probabilitas, dan faktor risiko klinis yang terdeteksi.
5. Bila input kosong/tidak valid, muncul dialog peringatan yang menjelaskan kesalahannya — perbaiki lalu coba lagi.
6. Tekan Reset untuk mengembalikan form ke nilai awal.

6.4 Melatih Ulang Model (Opsional)

Buka `src/diabetes_model_development.ipynb` (Jupyter) dan jalankan seluruh sel. Notebook melakukan EDA, split stratified, preprocessing, pelatihan Model A vs B, evaluasi lengkap, lalu menulis ulang `artifacts/model.keras` dan `artifacts/preprocessor.pkl` yang langsung dipakai aplikasi.

BAB 7 PENUTUP

7.1 Kesimpulan

1. Pipeline data klinis 96.146 sampel dibangun bebas kebocoran data: split stratified 70:15:15 mendahului preprocessing; scaler/encoder di-fit hanya pada train; objek yang sama dipakai ulang saat inferensi GUI.
2. Class imbalance 10,3 : 1 diatasi dengan class weighting balanced dan decision threshold tuning — akurasi tidak dijadikan metrik tunggal (Accuracy Paradox).
3. Komparasi dua arsitektur custom MLP menunjukkan Model B (Softmax + BatchNorm, 15→128→64→32→2) sebagai yang terbaik: Accuracy 97,24 %, Precision 97,40 %, Recall 70,60 %, F1 0,8186, ROC-AUC 0,977 pada Test Set.
4. Formulasi sigmoid vs softmax terbukti ekuivalen secara kapasitas (ROC-AUC hampir identik); pilihan akhir ditentukan oleh desain arsitektur dan hasil empiris.
5. Aplikasi desktop "Diabetes Prediction System" berhasil mengintegrasikan model, pipeline, validasi input, dan inferensi real-time dengan kode warna diagnosis yang intuitif.

7.2 Saran Pengembangan

- Eksplorasi ambang berbasis kurva ROC (Youden's J) atau biaya klinis FP/FN asimetris.
- Teknik mitigasi imbalance lanjutan: SMOTE, focal loss, atau ensemble.
- Penambahan fitur rekam medis lain dan validasi eksternal pada data rumah sakit riil.
- Kalibrasi probabilitas (Platt/Isotonic) dan kemasan distribusi (PyInstaller) menjadi executable satu berkas.

BAB 8 LAMPIRAN — STRUKTUR REPOSITORI & DEPENDENSI

```
DSEC_Diabetes_Prediction_Project/
├─ diabetes_prediction_dataset.csv      # dataset Kaggle (100.000 baris)
├─ Diabetes_Prediction_Project.pdf      # naskah tugas
├─ README.md, requirements.txt
├─ src/
│   ├─ diabetes_model_development.ipynb # Fase I: EDA → training → ekspor
│   ├─ app.py                          # Fase II+III: GUI + integrasi inferensi
│   ├─ test_backend.py                  # uji mandiri backend
│   └─ make_submission_zip.py           # pembuat berkas pengumpulan .zip
├─ artifacts/
│   ├─ model.keras                     # Model B terlatih (produksi)
│   ├─ preprocessor.pkl                 # scaler+encoder+ambang optimal
│   └─ training_history.json
├─ assets/figures/                     # seluruh figur laporan
└─ laporan/
    ├─ Laporan_Teknis_Prediksi_Diabetes.pdf
    └─ build_report.py                  # generator laporan
```

requirements.txt

```
tensorflow>=2.16
pandas>=2.0
numpy>=1.26
scikit-learn>=1.4
joblib>=1.3
matplotlib>=3.8
seaborn>=0.13
customtkinter>=5.2
```